


Les Arbres de Décision


Le guide de référence de l'apprentissage supervisé non paramétrique.



Réalisé par : Ferdaous Attioui

DE LA DONNÉE À LA RÈGLE

Un arbre de décision organise une série de règles sous forme de structure arborescente.
L'objectif est de prédire la valeur d'une cible en apprenant des règles de décision
dédiées directement des données d'entraînement.



MÉTHODE : Apprentissage supervisé
non paramétrique.

L'ANATOMIE DE L'ARBRE

Nœud racine :

Le point de départ. Représente l'ensemble de la population analysée.



Nœud racine

Scission (Splitting) :


Le processus de division d'un nœud en sous-nœuds.



Nœud de décision




Nœud de décision



Nœud feuille



Nœud feuille



Nœud feuille



Nœud feuille



Nœud feuille



Nœud feuille



Nœud feuille




Nœud feuille

Nœud feuille :

Les nœuds terminaux qui n'ont plus de sous-nœuds scindés.


La Construction des Règles

L'arbre se construit en testant des règles de décision à partir des caractéristiques (features) du jeu de données.




Dans une application réelle, il existe une multitude de règles.
Le défi : comment choisir la meilleure règle pour scinder le nœud actuel ?

L'Impureté de Gini




Impureté de Gini = 0.5.
Le groupe est mélangé à parts égales
(moitié-moitié).



Impureté de Gini = 0.0.
Le groupe est pur (tous les enregistrements
appartiennent à la même classe).


Le Moteur : Le Gain d'Information

Le gain d'information est la pièce maîtresse du processus de scission. Il mesure l'augmentation de la pureté après une division.



Gain d'Information = (Impureté du groupe parent) - (Moyenne pondérée des impuretés des groupes enfants).

La Boucle Algorithmique



Les Conditions d'Arrêt


L'arbre cesse de croître (de se scinder) de manière récursive lorsque l'une de ces conditions est remplie :



Un arrêt précoce est souvent utilisé pour éviter un nombre excessif de scissions.

Émettre une Prédiction


L'arbre de décision prédit la probabilité de chaque classe en se basant sur le ratio des classes présentes dans le nœud feuille final.



Cas pratique :

Pour un enregistrement où la taille est ≥ 2 et la couleur est jaune, si le nœud feuille contient autant de chaque classe, l'arbre prévoira qu'il y a 50% de chances que l'enregistrement soit un cercle.

Les Forces du Modèle



Interprétabilité :


La logique de décision est transparente, imitant le **raisonnement humain**.

Visualisation :

La structure en arbre est directe et extrêmement facile à représenter graphiquement.

La Faille Critique : Le Surapprentissage


L'inconvénient majeur : un modèle d'arbre de décision unique est particulièrement sujet au surapprentissage (overfitting).



Ce risque est **exacerbé lorsque l'arbre devient excessivement profond et complexe**. Il commence à mémoriser le bruit des données d'entraînement au lieu d'en apprendre les règles générales.

Défense 1 : L'Élagage (Pruning)



L'élagage consiste à supprimer les sous-nœuds d'un nœud de décision.



C'est le processus inverse (upside process) de la scission. Il force l'arbre à rester simple et généraliste, bloquant ainsi le surapprentissage.

Défense 2: La Profondeur Maximale

Définir une profondeur maximale de l'arbre (max depth) est une méthode courante pour combattre le surapprentissage.




Le compromis : Cette limite réduit considérablement le risque de surapprentissage, mais se fait au détriment d'une augmentation du biais du modèle.

L'Évolution : La Forêt Aléatoire

Comment prévenir le surapprentissage sans sacrifier le biais ?

La forêt aléatoire (Random Forest) est une technique de modélisation d'ensemble puissante. Il s'agit simplement d'une collection d'arbres de décision dont les résultats individuels sont agrégés en un seul résultat final. Le modèle devient ainsi beaucoup plus robuste qu'un arbre de décision unique.



Le Verdict Architectural

Dimension	Arbre de Décision Unique	Forêt Aléatoire
Complexité	Simple	Complexe (Ensemble)
Risque de Surapprentissage	<u>Très Élevé</u>	<u>Faible</u>
Interprétabilité	Transparente (Facile)	Boîte Noire (Difficile)
Robustesse	<u>Faible</u>	<u>Très Forte</u>

Conclusion : Dans les applications du monde réel, les data scientists privilégient directement la Forêt Aléatoire pour sa fiabilité et sa robustesse supérieures.